

CS-PAPERSUM: Um Conjunto de Dados em Larga Escala de Resumos Gerados por IA para Artigos Científicos

Javin Liu, Aryan Vats, Zihao He
University of Southern California

Resumo: A rápida expansão da literatura científica em ciência da computação apresenta desafios no acompanhamento das tendências de pesquisa e na extração de insights importantes. Os conjuntos de dados existentes fornecem metadados, mas carecem de resumos estruturados que capturem as principais contribuições e metodologias. Introduzimos o CS-PAPERSUM, um conjunto de dados em larga escala de 91.919 artigos de 31 conferências de ciência da computação de alto nível, enriquecidos com resumos estruturados gerados por IA usando o ChatGPT. Para avaliar a qualidade do resumo, conduzimos uma análise de alinhamento de embedding e de sobreposição de palavras-chave, demonstrando uma forte preservação dos conceitos-chave. Apresentamos também um estudo de caso sobre tendências de pesquisa em IA, destacando mudanças em metodologias e cruzamentos interdisciplinares, incluindo a ascensão do aprendizado autossupervisionado, geração aumentada por recuperação (RAG) e IA multimodal. Nosso conjunto de dados permite análise automatizada de literatura, previsão de tendências de pesquisa e descoberta científica impulsionada por IA, fornecendo um recurso valioso para pesquisadores, formuladores de políticas e sistemas de recuperação de informações científicas.

1. Introdução

A rápida expansão da literatura científica em ciência da computação criou desafios significativos para os pesquisadores que tentam se manter informados sobre novos desenvolvimentos, acompanhar tendências emergentes e sintetizar insights de um número esmagador de publicações. A cada ano, milhares de artigos são publicados em locais de alto nível, abrangendo uma ampla gama de subcampos, incluindo inteligência artificial, processamento de linguagem natural, visão computacional e segurança cibernética. Repositórios de acesso aberto e conjuntos de dados ricos em metadados, como o Semantic Scholar Open Research Corpus (S2ORC) e o Microsoft Academic Graph (MAG), fornecem informações bibliográficas, resumos e redes de citação, mas carecem de resumos estruturados que capturem as contribuições centrais, metodologias e direções de pesquisa futura. Para enfrentar esses desafios, introduzimos o CS-PAPERSUM, um conjunto de dados em larga escala com 91.919 artigos extraídos de 31 das principais conferências, incorporando resumos estruturados gerados pelo GPT-3.5.

2. Trabalhos Relacionados

Nosso trabalho se baseia em esforços anteriores na análise da literatura científica, sumarização automática e detecção de tendências de pesquisa impulsionadas por IA. Vários conjuntos de dados em larga escala (como S2ORC e MAG) fornecem acesso a artigos científicos e metadados, facilitando estudos bibliométricos, mas carecem de resumos de pesquisa estruturados. A sumarização automática de artigos

científicos tem sido amplamente estudada em PLN (Processamento de Linguagem Natural), com avanços recentes alavancando a sumarização abstrativa neural (como SciBERT e SPECTER). O CS-PAPERSUM estende essa pesquisa integrando resumos gerados pelo ChatGPT, fornecendo um novo recurso para avaliar a sumarização baseada em LLM no domínio científico.

3. Dados

3.1 Coleta de Dados e Conteúdo

Coletamos artigos de acesso aberto usando a API do Semantic Scholar, focando nas principais conferências de ciência da computação. O conjunto final abrange 91.919 artigos de 31 conferências (de 2017 a 2024), cobrindo IA, visão computacional, PLN, teoria computacional e arquitetura. Para cada artigo, extraímos: Título, Autores, Conferência, ano, resumo e contagem de citações. A extração da conclusão foi realizada via GROBID, convertendo PDFs em XML.

3.2 e 3.3 Estatísticas e Afiliações Produtivas

A distribuição revela conferências de alto impacto (NeurIPS, CVPR, ACL, etc.) e um aumento constante de publicações ao longo dos anos. A análise das afiliações mostra a dominância de universidades de elite (MIT, Stanford, CMU, etc.), forte presença de laboratórios da indústria (Google, DeepMind, Microsoft) e a distribuição regional liderada pelos EUA, seguida por Europa e o substancial crescimento da Ásia (como Tsinghua University).

3.4 Conferências Influentes

A influência, medida pela mediana de citações, coloca conferências de IA e visão computacional (CVPR, ICLR, ICCV) no topo. Além da IA, conferências de segurança (NDSS, USENIX) e linguagens/arquitetura (PLDI, ASPLOS) demonstram influência substancial, sublinhando a importância da cibersegurança e da computação paralela.

4. Resumindo os Artigos

Para aumentar a utilidade, geramos resumos estruturados de cada artigo usando o ChatGPT (GPT-3.5). Solicitamos ao modelo que extraísse os principais insights em um formato de lista estruturada a partir do título, resumo e conclusão. O formato padrão inclui: Principais Conclusões, Importância, Modelo/Método Proposto, Desempenho, Eficácia e Trabalhos Futuros.

4.1 Avaliação de Qualidade

Avaliamos a confiabilidade via alinhamento de embedding (usando SciBERT e t-SNE) e análise de sobreposição de palavras-chave (usando KeyBERT). Os resultados indicam que os resumos retêm fortemente a semântica, as características e as palavras-chave originais, validando a eficácia do ChatGPT neste domínio.

4.2 Estudo de Caso: Identificando Tendências de Pesquisa

Analizamos tendências na NeurIPS, AAAI, EMNLP e ICCV. Na NeurIPS, o foco migrou de aprendizagem por reforço clássica para Redes Neurais em Grafos (GNNs) e aprendizado autossupervisionado. Na AAAI, há um crescimento no foco de IA confiável, ética e colaboração humano-IA. A EMNLP mudou drasticamente da tradução estatística para transformers, RAG (Geração Aumentada por Recuperação) e sintonia de instruções. Na ICCV, o campo passou da detecção clássica para campos de radiância neural (NeRFs) e modelos de difusão.

5. Conclusão

Introduzimos o CS-PAPERSUM, um conjunto de dados enriquecido que fornece resumos padronizados para preencher a lacuna entre dados bibliográficos e insights acionáveis. O dataset permite análise de tendências e fornece base para sistemas futuros baseados em RAG e sumarização multi-documento para a descoberta científica.