

CS-PAPERSUM: Um Conjunto de Dados em Larga Escala de Resumos Gerados por IA para Artigos Científicos

Javin Liu (javinliu@usc.edu) - University of Southern California

Aryan Vats (aryanvat@usc.edu) - University of Southern California

Zihao He (zihaoh@usc.edu) - University of Southern California

Resumo: A rápida expansão da literatura científica em ciência da computação apresenta desafios no acompanhamento das tendências de pesquisa e na extração de insights importantes. Os conjuntos de dados existentes fornecem metadados, mas carecem de resumos estruturados que capturem as principais contribuições e metodologias. Introduzimos o CS-PAPERSUM, um conjunto de dados em larga escala de 91.919 artigos de 31 conferências de ciência da computação de alto nível, enriquecidos com resumos estruturados gerados por IA usando o ChatGPT. Para avaliar a qualidade do resumo, conduzimos uma análise de alinhamento de embedding e análise de sobreposição de palavras-chave, demonstrando uma forte preservação dos conceitos-chave. Apresentamos ainda um estudo de caso sobre tendências de pesquisa em IA, destacando mudanças em metodologias e cruzamentos interdisciplinares, incluindo a ascensão do aprendizado autossupervisionado, geração aumentada por recuperação (RAG) e IA multimodal. Nosso conjunto de dados permite análise automatizada de literatura, previsão de tendências de pesquisa e descoberta científica impulsionada por IA, fornecendo um recurso valioso para pesquisadores, formuladores de políticas e sistemas de recuperação de informações científicas.

1. Introdução

A rápida expansão da literatura científica em ciência da computação criou desafios significativos para os pesquisadores que tentam se manter informados sobre novos desenvolvimentos, acompanhar tendências emergentes e sintetizar insights de um número esmagador de publicações. A cada ano, milhares de artigos são publicados em locais de alto nível, abrangendo uma ampla gama de subcampos, incluindo inteligência artificial, processamento de linguagem natural, visão computacional e segurança cibernética. À medida que o ritmo da pesquisa se acelera, a capacidade de extrair eficientemente insights importantes do vasto corpo de literatura científica tornou-se cada vez mais importante. Repositórios de acesso aberto existentes e conjuntos de dados ricos em metadados, como o Semantic Scholar Open Research Corpus (S2ORC) [38] e o Microsoft Academic Graph (MAG) [55], fornecem informações bibliográficas, resumos e redes de citação, mas carecem de resumos estruturados que capturem as contribuições centrais, metodologias e direções futuras de pesquisa de artigos individuais. Essa limitação dificulta a análise automatizada em larga escala do progresso da pesquisa, impedindo o desenvolvimento de ferramentas baseadas em IA para síntese de literatura e detecção de tendências.

Para enfrentar esses desafios, introduzimos o CS-PAPERSUM, um conjunto de dados em larga escala de 91.919 artigos de ciência da computação extraídos de 31 conferências principais. Ao contrário de conjuntos de dados anteriores que fornecem principalmente texto bruto e metadados, o CS-PAPERSUM incorpora resumos estruturados gerados por IA produzidos usando o GPT-3.5 [49]. Cada resumo destila as principais contribuições do artigo, metodologias inovadoras, métricas de avaliação e direções futuras de pesquisa, oferecendo uma visão concisa, porém abrangente, de seu conteúdo. Ao padronizar essas informações em uma ampla coleção de

artigos, o conjunto de dados permite estudos cienciométricos em larga escala, revisões automatizadas de literatura e síntese de pesquisa auxiliada por IA.

A motivação para a construção deste conjunto de dados surge de vários desafios críticos na análise de artigos científicos. O enorme volume de produção de pesquisas torna impraticável para os acadêmicos ler e resumir manualmente artigos em grande escala, mesmo com a ajuda de mecanismos de busca e redes de citação [19]. Embora plataformas como o Google Scholar e o Semantic Scholar indexem um vasto número de publicações, elas não fornecem insights estruturados que ajudem os pesquisadores a entender rapidamente o significado de um artigo além de seu título e resumo. Além disso, as abordagens existentes para a análise de tendências de pesquisa, como a modelagem de tópicos [6], oferecem apenas insights de alto nível sem capturar as contribuições técnicas refinadas de estudos individuais. Aproveitando grandes modelos de linguagem para gerar resumos estruturados de artigos, o CS-PAPERSUM fornece uma solução escalável para extrair e organizar o conhecimento científico.

Para garantir a confiabilidade dos resumos gerados pela IA, conduzimos uma avaliação de qualidade minuciosa, avaliando o alinhamento semântico entre os resumos do ChatGPT e os artigos originais. Empregamos o SciBERT [5], um modelo transformer específico de domínio treinado em textos científicos, para gerar embeddings tanto para o conteúdo original do artigo quanto para os resumos gerados pela IA. A visualização usando a redução de dimensionalidade t-SNE demonstra que os embeddings dos resumos gerados pelo ChatGPT se alinham bem com os dos artigos originais, mantendo uma separação clara entre os diferentes domínios de pesquisa. Além disso, realizamos uma análise de sobreposição de palavras-chave usando o KeyBERT para comparar as palavras-chave extraídas dos resumos e do texto original. Altas porcentagens de sobreposição indicam que os resumos gerados pela IA preservam efetivamente conceitos-chave, tornando-os uma ferramenta confiável para síntese automatizada de literatura.

Além de avaliar a qualidade dos resumos, demonstramos uma aplicação prática do CS-PAPERSUM analisando tendências de pesquisa nas principais conferências de IA. Ao extrair os principais tópicos dos resumos estruturados, identificamos a evolução das áreas de foco de pesquisa na NeurIPS, AAAI, EMNLP e ICCV, revelando mudanças nas metodologias e intersecções interdisciplinares emergentes. Por exemplo, observamos uma transição na NeurIPS de métodos tradicionais de aprendizado por reforço [45] para redes neurais em grafos [7] e modelos de aprendizado autossupervisionado em larga escala [36]. Na pesquisa de PLN, a dominância da tradução automática estatística nos primeiros anos [34] foi substituída por arquiteturas baseadas em transformers pré-treinados [16], geração aumentada por recuperação [35] e técnicas eficientes de ajuste fino [29]. A pesquisa em visão computacional evoluiu de forma semelhante, com a ICCV mostrando um interesse crescente em vision transformers [18], redes adversárias generativas [22] e campos de radiância neural para reconstrução 3D [44]. O conjunto de dados também permite a detecção de tendências de pesquisa interdisciplinares, como a adoção de técnicas de aprendizado autossupervisionado originalmente desenvolvidas para visão [12] em aplicações de PLN [20].

O CS-PAPERSUM representa um passo significativo na estruturação e síntese automatizada do conhecimento científico. Ao fornecer um conjunto de dados em larga escala enriquecido com resumos estruturados gerados pelo ChatGPT, nosso objetivo é preencher a lacuna entre dados bibliográficos brutos e insights científicos acionáveis. O conjunto de dados permite a análise automatizada da literatura, facilita a detecção de tendências de pesquisa e fornece uma base para o desenvolvimento de sistemas de IA que auxiliam na descoberta científica. À medida que o cenário da IA e da ciência da computação continua a evoluir, conjuntos de dados

como o CS-PAPERSUM desempenharão um papel crucial para tornar a literatura científica mais acessível, navegável e analisável em grande escala.

2. Trabalhos Relacionados

Nosso trabalho se baseia em esforços anteriores na análise da literatura científica, sumarização automática e detecção de tendências de pesquisa impulsionadas por IA.

Vários conjuntos de dados em larga escala fornecem acesso a artigos científicos e metadados, facilitando estudos bibliométricos e recuperação de informações. O Semantic Scholar Open Research Corpus (S2ORC) [38] contém artigos científicos em texto completo e metadados, suportando tarefas de PLN, como análise de citações e modelagem de tópicos. Da mesma forma, o Microsoft Academic Graph (MAG) [55] fornece um grande gráfico de conhecimento de publicações acadêmicas, incluindo redes de citação e afiliações de autores. Outros conjuntos de dados, como o CORE [33], concentram-se na agregação de artigos de pesquisa de acesso aberto. No entanto, esses recursos contêm principalmente texto bruto, resumos e metadados de citação, sem resumos estruturados das contribuições da pesquisa, dificultando a síntese de literatura em larga escala. O CS-PAPERSUM preenche essa lacuna fornecendo resumos concisos e gerados por IA que capturam as principais conclusões, metodologias e direções futuras de cada artigo.

A sumarização automática de artigos científicos tem sido amplamente estudada em PLN, particularmente em sumarização extrativa e abstrativa. As abordagens iniciais usavam métodos extrativos, selecionando frases-chave com base na saliência e classificação [40]. Avanços mais recentes aproveitam a sumarização abstrativa neural, gerando resumos coerentes com transformers e modelos de linguagem pré-treinados [17]. O SciBERT [5] e o SPECTER [14] foram desenvolvidos para o processamento de textos científicos, melhorando as representações contextuais de artigos de pesquisa. Nosso conjunto de dados amplia essa pesquisa integrando resumos estruturados gerados pelo ChatGPT, fornecendo um novo recurso em larga escala para avaliar a sumarização baseada em LLMs no domínio científico.

Estudos recentes exploraram a análise de tendências científicas usando redes de citação e modelagem de tópicos. Chen et al. [10] investigaram a evolução de campos científicos usando clusterização baseada em citações, enquanto Blei et al. [6] introduziram a Alocação Latente de Dirichlet (LDA) para detectar tópicos emergentes na literatura de pesquisa. Outros trabalhos examinaram as tendências de pesquisa usando redes de coautoria [47] e análise de co-ocorrência de palavras-chave [46]. No entanto, essas abordagens dependem principalmente de grafos de citação e distribuições de palavras, e não de resumos de pesquisa estruturados, o que limita sua capacidade de capturar as nuances de metodologias e descobertas experimentais em evolução. O CS-PAPERSUM permite a análise de tendências de granulação fina, fornecendo resumos gerados por IA que destacam explicitamente as principais contribuições, insights experimentais e direções de pesquisa futuras.

3. Dados

3.1 Coleta de Dados e Conteúdo

Coletamos artigos científicos de acesso aberto usando a API do Semantic Scholar [32], com foco nas principais conferências de ciência da computação abrangendo vários subcampos. Após o processamento, nosso conjunto de dados compreende 91.919 artigos de 31 conferências, cobrindo áreas diversas como inteligência artificial,

visão computacional, processamento de linguagem natural, teoria computacional e arquitetura de computadores. Uma lista completa das conferências incluídas no conjunto de dados é fornecida na Tabela 1.

Nosso conjunto de dados abrange de 2017 a 2024, oferecendo uma visão longitudinal abrangente dos avanços recentes na pesquisa em ciência da computação. A inclusão de artigos de vários anos permite a análise temporal de tendências, tornando possível acompanhar a evolução de tópicos-chave, mudanças no foco da pesquisa e o crescimento de diferentes subcampos.

Para cada artigo, extraímos e incluímos os seguintes metadados: Título, Autores, Conferência, ano de publicação, resumo e contagem de citações. A extração da seção de conclusão é realizada usando o GROBID [1], uma ferramenta baseada em aprendizado de máquina para análise de documentos científicos. Convertemos o PDF de cada artigo em formato XML estruturado e identificamos a seção de conclusão procurando a última seção enumerada contendo palavras-chave como "conclusion" ou "discussion". Essa abordagem garante a captura das principais conclusões de cada artigo, que costumam ser úteis para meta-análises, sumarização automática e previsão de tendências de pesquisa.

Tabela 1: Lista categorizada de conferências incluídas.

Subcampo de Pesquisa	Conferência
Computação em Áreas Biomédicas	MICCAI, ISBI
Processamento de Linguagem Natural	EMNLP, ACL
Visão Computacional	CVPR, ICCV
Inteligência Artificial	AAAI, ICLR
Teoria Computacional	NeurIPS, AISTATS, COLT
Hardware & Arquitetura	MICRO, HCPA
Redes e Comunicações	WWW, CCS, INFOCOM
Segurança e Criptografia	NDSS, USENIX, TCC, Crypto
Banco de Dados e Sistemas	WADS, CIKM
Gráficos e CAD	FG, ICME
Interação Humano-Computador	CHI, HRI
Realidade Mista e Aumentada	VRIC, ISMAR
Engenharia de Software	ICSE, ASPLOS, PLDI

3.2 Estatísticas

A distribuição de artigos por conferência destaca as relativas contribuições de diferentes locais (ex: NeurIPS com 15.1%, AAAI com 11.4%, CVPR com 10.2%). A distribuição anual dos artigos é detalhada na Tabela 2, mostrando um aumento geral nas publicações ao longo do tempo. Esta tendência reflete o volume crescente de

contribuições de pesquisa em ciência da computação, impulsionado pelos avanços em IA, ML e outros subcampos. Notavelmente, de 2017 a 2023, o número de artigos mais que dobrou, indicando um ritmo acelerado de produção de pesquisa.

Tabela 2: Número de artigos publicados por ano de 2017 a 2024.

Ano	2017	2018	2019	2020	2021	2022	2023	2024
Quantidade	8.120	8.704	12.642	13.130	14.851	15.491	18.461	520

3.3 Afiliações Produtivas

Entender as instituições que mais contribuem para pesquisas de ponta é essencial. Analisamos as afiliações mais produtivas rastreando o número de artigos publicados por universidades, laboratórios de pesquisa e organizações do setor. A partir de nossa análise, observamos várias tendências fundamentais:

- **Dominância de universidades de pesquisa de elite:** Instituições prestigiadas como MIT, Stanford, Carnegie Mellon University (CMU), UC Berkeley, Universidade de Oxford e Universidade de Toronto estão consistentemente entre os maiores contribuintes.
- **Forte presença de laboratórios da indústria:** Empresas de tecnologia líderes como Google Research, DeepMind, Microsoft Research, Meta AI e NVIDIA Research contribuem significativamente.
- **Distribuição regional:** A América do Norte domina (especialmente EUA). A Europa mantém forte presença (Oxford, Cambridge, ETH Zurich). A Ásia tem visto crescimento substancial, particularmente com a Tsinghua University, Peking University e National University of Singapore.

3.4 Conferências Influentes

Avaliamos a influência das conferências usando a contagem mediana de citações dos artigos publicados. A Tabela 3 apresenta as 10 conferências mais impactantes com base nesta métrica.

Tabela 3: Top 10 conferências classificadas pela mediana de citações.

Conferência	Impacto	Conferência	Impacto
CVPR	34	CHI	16
ICLR	25	USENIX	15
ICCV	20	ASPLOS	14
NDSS	19	COLT	14
PLDI	16	HPCA	13

A análise revela que conferências em IA e visão computacional (CVPR, ICLR, ICCV) estão consistentemente no topo. O CVPR, em particular, lidera o impacto de citações, refletindo as aplicações generalizadas da pesquisa em visão computacional. Conferências em segurança (NDSS, USENIX), linguagens de programação e arquitetura de sistemas (PLDI, ASPLOS) também demonstram influência substancial.

4. Resumindo os Artigos

Para aumentar a usabilidade e acessibilidade do nosso conjunto de dados, geramos resumos estruturados de cada artigo usando o ChatGPT (GPT-3.5) [49]. A motivação é dupla: facilitar a recuperação eficiente de informações na literatura em rápido crescimento, e padronizar as principais conclusões que muitas vezes faltam nos metadados puros. Solicitamos ao ChatGPT que extraia insights chave num formato estruturado de lista usando o seguinte prompt (em inglês):

```
You will help summarize research. Given an paper title and abstract
summarize the key takeaways, importance of the paper, what does
the paper bring to the table that was unique from previous works,
identify and list the key topics, models, and techniques discussed.
Focus on condensing these elements into a concise list format. Each
list item should represent a distinct topic or technique mentioned in
the paper which is one to two words, any future works, performance
measures (f1 score, accuracy, etc of the work/other works mentioned),
performance effectiveness with 3 possible values highly effective not
effective or moderately effective, future works, sentiments for the mod-
els/techniques, score for paper influence between 0 to 10. Return in
the following format.
```

```
Key Takeaways:
```

```
Importance: xxx
```

```
Model/Method Proposed: xxx
```

```
Performance: xxx
```

```
Effectiveness: xxx
```

```
Future Work: xxx
```

```
For Key Takeaways, Importance, and Model/Method Proposed, please
have at least 5 points in bullet point format.
```

```
Title: [title]
```

```
Abstract: [abstract]
```

```
Conclusion: [conclusion]
```

4.1 Avaliação de Qualidade dos Resumos

Realizamos uma análise de alinhamento de embeddings e sobreposição de palavras-chave. Usando SciBERT [5] e t-SNE, a visualização demonstrou que os embeddings dos resumos do ChatGPT mantêm a estrutura semântica dos artigos originais. Além disso, a extração de palavras-chave via KeyBERT mostrou um alto grau de sobreposição, provando que as terminologias centrais foram preservadas efetivamente.

4.2 Estudo de Caso: Identificando Tendências de Pesquisa

Uma aplicação chave do CS-PAPERSUM é sua capacidade de descobrir tendências de pesquisa. Analisamos a NeurIPS, AACL, EMNLP e ICCV. Extraíndo as palavras-chave mais frequentes, mapeamos a evolução temporal dos temas (Tabela 4).

Tabela 4: Principais palavras-chave extraídas das maiores conferências de IA.

Conferência	Palavras-Chave Principais
NeurIPS	adversarial, neural networks, object detection, reinforce learning, gradient descent, multi agent, domain adaptation
AAAI	machine translation, text generation, language models, word embeddings, relation extraction
EMNLP	language models, large language models, word embeddings, relation extraction, event extraction
ICCV	knowledge graph, semantic analysis, inpainting, pose, style transfer, scene text, generative adversarial

Observamos cruzamentos interdisciplinares, como o Aprendizado Autossupervisionado (SSL), popularizado na Visão Computacional, se tornando dominante no PLN. Identificamos também abordagens híbridas emergentes (IA Neuro-Simbólica) na AAAI e NeurIPS.

5. Conclusão

Introduzimos o CS-PAPERSUM, um conjunto de dados de 91.919 artigos de 31 conferências, enriquecidos com resumos do ChatGPT. Demonstramos que os resumos gerados por IA preservam as características semânticas, permitindo estudos cienciométricos em larga escala. Além da análise de tendências, o conjunto de dados abre caminhos promissores como a criação de benchmarks de sumarização, desenvolvimento de ferramentas automáticas de revisão, integração com a geração aumentada por recuperação (RAG) e modelos de sumarização de múltiplos documentos.

Agradecimentos

Agradecemos a Dennis Perepech e Aryan Vats por sua ajuda.

Referências

- [1] 2008-2025. GROBID. <https://github.com/kermitt2/grobid>.
- [2] Jean-Baptiste Alayrac, et al. 2022. Flamingo: a visual language model for few-shot learning. *Advances in neural information processing systems* 35 (2022), 23716-23736.
- [3] Dario Amodei, et al. 2016. Concrete problems in AI safety. *arXiv preprint arXiv:1606.06565* (2016).
- [4] Tadas Baltrušaitis, et al. 2018. Multimodal machine learning: A survey and taxonomy. *IEEE transactions on pattern analysis and machine intelligence* 41, 2 (2018), 423-443.
- [5] Iz Beltagy, Kyle Lo, and Arman Cohan. 2019. SciBERT: A Pretrained Language Model for Scientific Text. In *EMNLP-IJCNLP*.
- [6] David M Blei, Andrew Y Ng, and Michael I Jordan. 2003. Latent dirichlet allocation. *Journal of machine Learning research* 3, Jan (2003), 993-1022.
- [7] Michael M Bronstein, et al. 2021. Geometric deep learning. *arXiv preprint arXiv:2104.13478*.
- [8] Tom Brown, et al. 2020. Language models are few-shot learners. *NeurIPS* 33, 1877-1901.

- [9] Mathilde Caron, et al. 2021. Emerging properties in self-supervised vision transformers. ICCV, 9650-9660.
- [10] Chaomei Chen. 2017. Science mapping: a systematic review of the literature. *Journal of data and information science* 2, 2 (2017).
- [11] Kai Chen, et al. 2024. How Susceptible are Large Language Models to Ideological Manipulation?. EMNLP.
- [12] Ting Chen, et al. 2020. A simple framework for contrastive learning of visual representations. ICML, 1597-1607.
- [13] Minh Duc Chu, et al. 2024. Improving and Assessing the Fidelity of Large Language Models Alignment to Online Communities. arXiv:2408.09366.
- [14] Arman Cohan, et al. 2020. SPECTER: Document-level Representation Learning using Citation-informed Transformers. ACL.
- [15] Tim Dettmers, et al. 2023. Qlora: Efficient finetuning of quantized llms. NeurIPS 36.
- [16] Jacob Devlin, et al. 2019. Bert: Pre-training of deep bidirectional transformers for language understanding. NAACL.
- [17] Jay DeYoung, et al. 2021. MS 2: Multi-Document Summarization of Medical Studies. EMNLP.
- [18] Alexey Dosovitskiy, et al. 2020. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv: 2010.11929.
- [19] Santo Fortunato, et al. 2018. Science of science. *Science* 359, 6379.
- [20] Tianyu Gao, Xingcheng Yao, and Danqi Chen. 2021. SimCSE: Simple Contrastive Learning of Sentence Embeddings. EMNLP.
- [21] Artur d'Avila Garcez, et al. 2019. Neural-symbolic computing. arXiv:1905.06088.
- [22] Ian Goodfellow, et al. 2014. Generative adversarial nets. NeurIPS 27.
- [23] Jean-Bastien Grill, et al. 2020. Bootstrap your own latent. NeurIPS 33.
- [24] Zihao He, et al. 2024. Community-Cross-Instruct: Unsupervised Instruction Generation. EMNLP.
- [25] Zihao He, et al. 2024. Whose Emotions and Moral Sentiments do Language Models Reflect?. ACL.
- [26] Zihao He, et al. 2023. ALCAP: Alignment-Augmented Music Captioner. EMNLP.
- [27] Zihao He, et al. 2024. Reading Between the Tweets. EACL.
- [28] Jonathan Ho, et al. 2020. Denoising diffusion probabilistic models. NeurIPS 33.
- [29] Neil Houlsby, et al. 2019. Parameter-efficient transfer learning for NLP. ICML.
- [30] Anna Jobin, et al. 2019. The global landscape of AI ethics guidelines. *Nature machine intelligence*.
- [31] Peter Kairouz, et al. 2021. Advances and open problems in federated learning. *Foundations and trends in machine learning*.
- [32] Rodney Kinney, et al. 2023. The semantic scholar open data platform. arXiv:2301.10140.
- [33] Petr Knuth and Zdenek Zdrahal. 2012. CORE: three access levels to underpin open access. *D-Lib Magazine*.
- [34] Philipp Koehn, et al. 2003. Statistical phrase-based translation. NAACL.
- [35] Patrick Lewis, et al. 2020. Retrieval-augmented generation for knowledge-intensive nlp tasks. NeurIPS 33.
- [36] Hong Liu, et al. 2021. Self-supervised Learning is More Robust to Dataset Imbalance. ICLR.
- [37] Haotian Liu, et al. 2023. Visual instruction tuning. NeurIPS 36.
- [38] Kyle Lo, et al. 2020. S2ORC: The Semantic Scholar Open Research Corpus. ACL.
- [39] Jonathan Long, et al. 2015. Fully convolutional networks for semantic segmentation. CVPR.
- [40] Annie Louis and Ani Nenkova. 2011. Automatic identification of general and specific sentences. IJCNLP.
- [41] Robin Manhaeve, et al. 2021. Neural probabilistic logic programming in DeepProbLog. *Artificial Intelligence*.

- [42] Christopher Manning and Hinrich Schutze. 1999. Foundations of statistical natural language processing. MIT press.
- [43] Ninareh Mehrabi, et al. 2021. A survey on bias and fairness in machine learning. ACM computing surveys.
- [44] Ben Mildenhall, et al. 2021. Nerf: Representing scenes as neural radiance fields. Commun. ACM.
- [45] Volodymyr Mnih, et al. 2015. Human-level control through deep reinforcement learning. Nature.
- [46] David Kongpiwatana Narong and Phillip Hallinger. 2023. A keyword co-occurrence analysis of research on service learning. Education Sciences.
- [47] Mark EJ Newman. 2001. The structure of scientific collaboration networks. PNAS.
- [48] Hieu Nguyen, et al. 2025. Smoothing Out Hallucinations: Mitigating LLM Hallucination. arXiv:2502.11306.
- [49] Long Ouyang, et al. 2022. Training language models to follow instructions with human feedback. NeurIPS 35.
- [50] Alec Radford, et al. 2021. Learning transferable visual models from natural language supervision. ICML.
- [51] Shaoqing Ren, et al. 2015. Faster r-cnn: Towards real-time object detection. NeurIPS 28.
- [52] Roy Schwartz, et al. 2020. Green ai. Commun. ACM.
- [53] Ben Shneiderman. 2020. Human-centered artificial intelligence. International Journal of Human-Computer Interaction.
- [54] David Silver, et al. 2017. Mastering the game of go without human knowledge. Nature.
- [55] Kuansan Wang, et al. 2020. Microsoft academic graph. Quantitative Science Studies.
- [56] Jason Wei, et al. 2022. Finetuned Language Models are Zero-Shot Learners. ICLR.
- [57] Laura Weidinger, et al. 2022. Taxonomy of risks posed by language models. ACM FAccT.